

Victor Augusto de Oliveira



FUNDAÇÃO HERMÍNIO OMETTO

**Projeto apresentado ao Comitê de Ética em Pesquisa
e Mérito Científico do Centro Universitário da
Fundação Hermínio Ometto, como parte da
integrante da avaliação do
Engenharia da Computação**

ORIENTADOR(A): Profº. Dr Maurício Acconcia Dias

ARARAS/SP

09/2025

Resumo

O monitoramento de lavouras em pequenas propriedades é um pilar essencial para a produtividade, mas enfrenta desafios significativos. Os métodos tradicionais de inspeção visual e contagem manual de pragas são trabalhosos, imprecisos e de baixa frequência, resultando em tomadas de decisão tardias e uso ineficiente de recursos. Diante dessa lacuna, este trabalho tem como objetivo principal desenvolver e validar um protótipo funcional de um sistema de monitoramento agrícola inteligente e de baixo custo. A metodologia será baseada na integração de três módulos: um nó de sensores IoT para a coleta de dados de solo e ambiente; uma armadilha fotográfica inteligente, utilizando um Raspberry Pi e uma Rede Neural Convolucional (CNN) baseada na arquitetura YOLO, para a detecção e classificação automática de pragas; e um módulo de câmeras para a análise da saúde da vegetação. Os dados coletados serão enviados para uma plataforma de gerenciamento web centralizada. Como resultados esperados, o sistema integrado deverá ser funcional, o modelo de CNN deverá atingir uma média de Precisão Média (mAP) satisfatória na identificação das pragas-alvo, e a plataforma web deverá exibir os alertas e dados dos sensores em tempo real. Espera-se, com isso, demonstrar a viabilidade técnica de uma solução de baixo custo para a automação do monitoramento, oferecendo ao pequeno produtor uma ferramenta acessível para a agricultura de precisão e a otimização do manejo.

1 – Introdução

A agricultura desempenha um papel fundamental na economia, sendo a agricultura familiar uma base essencial para a produção de alimentos. No entanto, produtores deste segmento frequentemente enfrentam desafios no gerenciamento de suas lavouras, dependendo de métodos manuais para monitorar fatores críticos como as condições do solo e a incidência de pragas. Este modelo tradicional de monitoramento é, muitas vezes, reativo, trabalhoso, lento e de baixa precisão, podendo levar a tomadas de decisão tardias.

A relevância deste estudo reside na busca por uma solução para mitigar tais desafios. A aplicação ineficiente de recursos, como água e defensivos agrícolas, não só eleva os custos de produção, mas também pode resultar em perdas de produtividade e impactos ambientais

negativos. Diante deste cenário, o presente trabalho aborda o tema propondo o desenvolvimento de um sistema de baixo custo que aplica os conceitos de Internet das Coisas (IoT) e Visão Computacional para automatizar e qualificar o monitoramento agrícola.

Para atingir esse objetivo, o estudo será realizado por meio do desenvolvimento e da integração de um sistema modular. Primeiramente, será construído um nó de sensores (Módulo 1) para a coleta de dados vitais do solo e do ambiente, como umidade e temperatura. Em paralelo, será desenvolvido o Módulo 2, uma armadilha fotográfica inteligente que utilizará visão computacional para a contagem e análise de pragas. Um terceiro módulo (Módulo 3) será implementado com câmeras para realizar o monitoramento geral da saúde da plantação. Por fim, todos os dados coletados por esses módulos serão centralizados em uma plataforma de gerenciamento web, que permitirá ao usuário final visualizar as informações de forma clara e intuitiva através de um dashboard, facilitando o gerenciamento da lavoura.

2 - Referencial Teórico

A modernização da agricultura, frequentemente denominada Agricultura 4.0, baseia-se na aplicação de tecnologias digitais para otimizar a produção, aumentar a eficiência e promover a sustentabilidade. Um dos pilares desta revolução é a Agricultura de Precisão, que trata as variações espaciais e temporais dentro da lavoura de forma individualizada, em contraste com a gestão uniforme tradicional. Nesse contexto, o monitoramento de fatores bióticos, como a incidência de pragas, é fundamental para a tomada de decisões agronômicas assertivas, especialmente no âmbito do Manejo Integrado de Pragas (MIP).

Os métodos convencionais para o monitoramento de pragas, como a contagem manual em armadilhas adesivas (cromotrópicas) ou a inspeção visual direta nas plantas, embora estabelecidos, apresentam desafios significativos. São processos intensivos em mão de obra, de baixa frequência de amostragem e suscetíveis à subjetividade e ao erro humano, o que pode levar a uma identificação tardia de infestações e, consequentemente, a perdas na produção ou ao uso excessivo de defensivos agrícolas.

Para superar essas limitações, a Visão Computacional, um campo da Inteligência Artificial (IA), oferece ferramentas poderosas para a análise automática de imagens. Através dela, é possível extrair informações relevantes de dados visuais, como fotografias ou vídeos. Nos últimos anos, o Deep Learning (DL), um subcampo da IA, revolucionou a visão computacional, principalmente com o advento das Redes Neurais Convolucionais (CNNs). As CNNs são arquiteturas de redes neurais profundas inspiradas no córtex visual humano, capazes de aprender automaticamente características hierárquicas diretamente dos pixels de uma imagem, eliminando a necessidade da complexa etapa de engenharia de características manuais exigida por algoritmos de Machine Learning tradicionais.

Dentro da visão computacional, a tarefa específica de “Detecção de Objetos” visa não apenas classificar o que está presente em uma imagem, mas também localizar espacialmente cada objeto de interesse através de uma caixa delimitadora (bounding box). Diversas arquiteturas de CNN foram propostas para essa tarefa. Entre elas, destaca-se a família YOLO (You Only Look Once), que aborda a detecção como um problema de regressão unificado, processando a imagem inteira de uma só vez para prever as caixas delimitadoras e as probabilidades de classe simultaneamente. Essa abordagem “single-stage” confere aos modelos YOLO uma alta velocidade de inferência, tornando-os adequados para aplicações em tempo real, como demonstrado em diversos estudos para detecção de pragas agrícolas. Versões mais recentes e leves, como YOLOv8 e YOLOv10, foram otimizadas para equilibrar precisão e eficiência computacional.

A implementação prática dessas soluções de IA no campo frequentemente requer o uso de sistemas embarcados, que são sistemas computacionais dedicados a uma função específica, operando com restrições de energia, custo e processamento. Microcomputadores de placa única, como o Raspberry Pi, oferecem uma plataforma acessível e flexível para prototipagem e implementação de sistemas embarcados, capazes de executar modelos de DL otimizados e interagir com sensores e câmeras. A otimização de modelos de CNN para execução nesses dispositivos é realizada através de frameworks como o TensorFlow Lite, que converte modelos treinados em formatos mais leves e eficientes para inferência "na borda" (edge computing).

Finalmente, para que os dados gerados pelos sistemas de monitoramento sejam úteis, eles precisam ser transmitidos para uma plataforma central. A Internet das Coisas (IoT) fornece os protocolos e a infraestrutura para essa comunicação. Protocolos leves de mensagens, como o MQTT (Message Queuing Telemetry Transport), são amplamente utilizados em IoT por serem eficientes em redes com baixa largura de banda e para dispositivos com recursos limitados, permitindo a comunicação assíncrona entre os sensores/dispositivos em campo e um servidor central (broker).

3 – Justificativa

A realização desta pesquisa se justifica por razões de ordem prática e acadêmica. Do ponto de vista prático, o setor da agricultura familiar carece de soluções tecnológicas acessíveis que otimizem o gerenciamento da lavoura. Os métodos tradicionais de monitoramento são, em geral, manuais, reativos e de baixa precisão, o que pode levar ao uso ineficiente de recursos hídricos e defensivos agrícolas, impactando diretamente a sustentabilidade financeira e ambiental da produção. A importância social do projeto reside no potencial de fortalecer a agricultura familiar, tornando-a mais competitiva e sustentável. Academicamente, o trabalho é relevante por integrar conhecimentos multidisciplinares de Engenharia de Computação, como Internet das Coisas (IoT), Visão Computacional e Desenvolvimento Web, para criar uma solução inovadora e de baixo custo no campo da Agricultura 4.0.

4 – Objetivo(s)

Objetivo Geral

Desenvolver um protótipo funcional de um sistema de monitoramento agrícola inteligente e de baixo custo, que integra dados de solo, ambiente e pragas para auxiliar na tomada de decisão de pequenos produtores.

Objetivos Específicos

- **Construir** um nó de monitoramento (Módulo 1) para coletar dados de umidade, pH e condutividade elétrica do solo, além de temperatura e umidade do ar.

- **Desenvolver** uma armadilha fotográfica inteligente (Módulo 2) utilizando visão computacional para detectar e quantificar a incidência de pragas agrícolas.
- **Implementar** um sistema de monitoramento por câmeras (Módulo 3) para analisar a saúde da vegetação a partir da análise de imagens.
- **Criar** uma plataforma de gerenciamento web (Plataforma de Gerenciamento) para centralizar, armazenar e exibir os dados coletados de forma intuitiva ao usuário.
- **Validar** a integração e o funcionamento do sistema completo em um ambiente de pequena escala.

5 – Material e Método

A pesquisa será caracterizada como um desenvolvimento tecnológico e experimental. Os procedimentos para a consecução dos objetivos serão executados de forma modular:

- **Módulo 1 (Nó de Solo e Ambiente):** Será utilizado um microcontrolador ESP32 conectado a sensores de umidade do solo (capacitivo), pH, condutividade elétrica (EC), luminosidade (BH1750) e um sensor BME280 para o clima. O método consistirá na programação do firmware para ler os dados dos sensores e transmiti-los via protocolo MQTT para a plataforma central.
- **Módulo 2 (Armadilha de Pragas):** Os materiais incluem um Raspberry Pi (Zero 2 W ou 4) e um Módulo de Câmera Oficial Pi. A técnica empregada será o desenvolvimento de um software em Python que utiliza bibliotecas de visão computacional (OpenCV) e uma Rede Neural Convolucional (CNN) para processar as imagens capturadas pela câmera, identificando e contando as pragas.
- **Módulo 3 (Monitoramento da Plantação):** Utilizará uma Câmera de Segurança Externa Wi-Fi PTZ e um Raspberry Pi 4. O método envolverá a captura de imagens em tempo real da plantação, as quais serão analisadas por um script para calcular um índice de vegetação a partir do espectro RGB, gerando um "mapa de saúde" da área monitorada.

- **Plataforma de Gerenciamento:** Será desenvolvida uma aplicação web utilizando um servidor Apache. O backend será responsável por receber e armazenar os dados dos módulos. O frontend será um dashboard que exibirá as informações de forma gráfica e intuitiva para o usuário. A integração de todos os módulos com a plataforma será realizada através do protocolo MQTT.

6 – Resultados e Discussão

Os resultados parciais deste trabalho demonstram a validação bem-sucedida de dois pilares do sistema: a infraestrutura de sensoriamento e comunicação IoT (Módulo 1) e o núcleo de inteligência artificial para a detecção de pragas (Software do Módulo 2).

6.1 Desenvolvimento e Validação do Módulo 1 (Nó de Sensores IoT)

A primeira etapa concluída consistiu na prototipagem e validação do hardware responsável pelo monitoramento das variáveis ambientais, essenciais para correlacionar o clima com a incidência de pragas.

6.1.1 Prototipagem do Hardware

O protótipo funcional foi construído utilizando um microcontrolador ESP32 (NodeMCU) como unidade central. Foram integrados sensores para leitura de umidade do solo (capacitivo) e sensores de temperatura e umidade do ar, montados em *protoboard* para validação lógica, conforme apresentado na Figura 1.

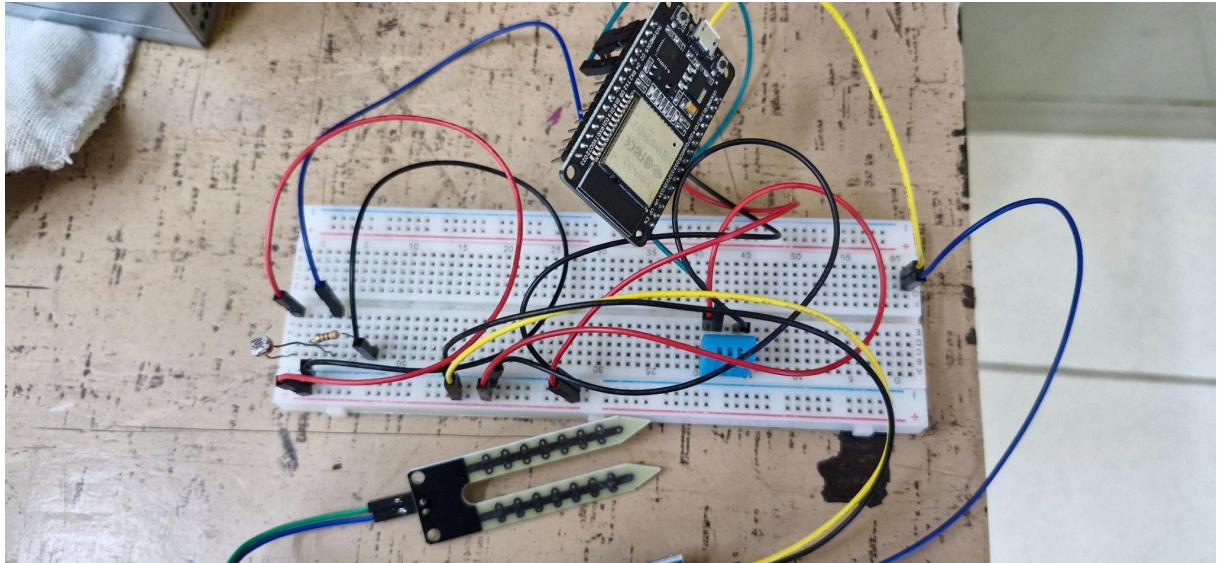


Figura 1 – Protótipo do Nô de Sensores (Módulo 1) Fonte: Elaborado pelo autor (2025).

Os testes de bancada confirmaram a estabilidade das leituras e a capacidade do ESP32 de processar e converter os sinais analógicos e digitais para as unidades de medida padrão.

6.1.2 Integração com Plataforma de Gerenciamento

A validação da conectividade foi realizada através da transmissão dos dados para a plataforma web (Adafruit IO) via protocolo MQTT. O sistema manteve conexão estável, enviando atualizações periódicas dos *feeds*. A Figura 2 exibe o *dashboard* apresentando dados em tempo real e gráficos históricos, comprovando a eficácia da telemetria.

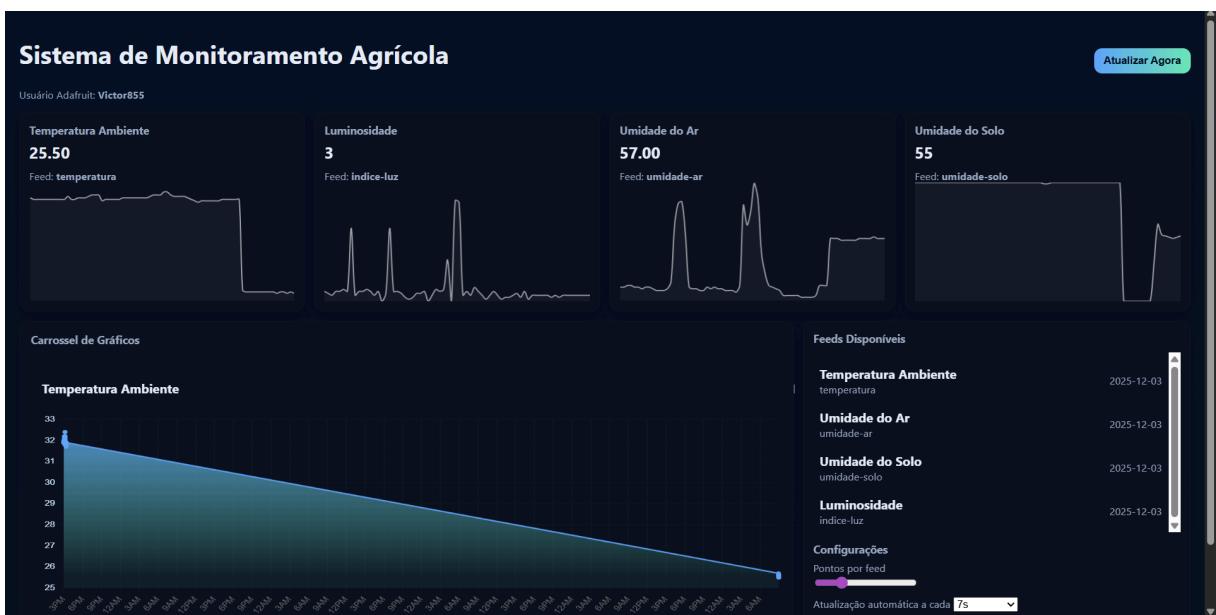


Figura 2 – Dashboard do Sistema de Monitoramento Agrícola Fonte: Elaborado pelo autor (2025).

6.2 Validação do Modelo de Detecção (Software Módulo 2)

Com a infraestrutura de comunicação validada, o foco voltou-se para o componente de software mais crítico: o algoritmo de detecção de pragas. A arquitetura YOLOv8s, treinada para identificar a *Trialeurodes vaporariorum* (mosca-branca), apresentou resultados robustos.

6.2.1 Desempenho Quantitativo e Eficiência

O modelo atingiu uma **precisão de 89,61%** no conjunto de teste, garantindo uma baixa taxa de falsos positivos. A **média da Precisão Média (mAP@0.5)** foi de **75,46%**.

Em termos de eficiência, o teste de latência (Figura 3) registrou um tempo médio de inferência de **13,98 ms** em GPU, correspondendo a **71,6 FPS**, validando a viabilidade para processamento em tempo real.

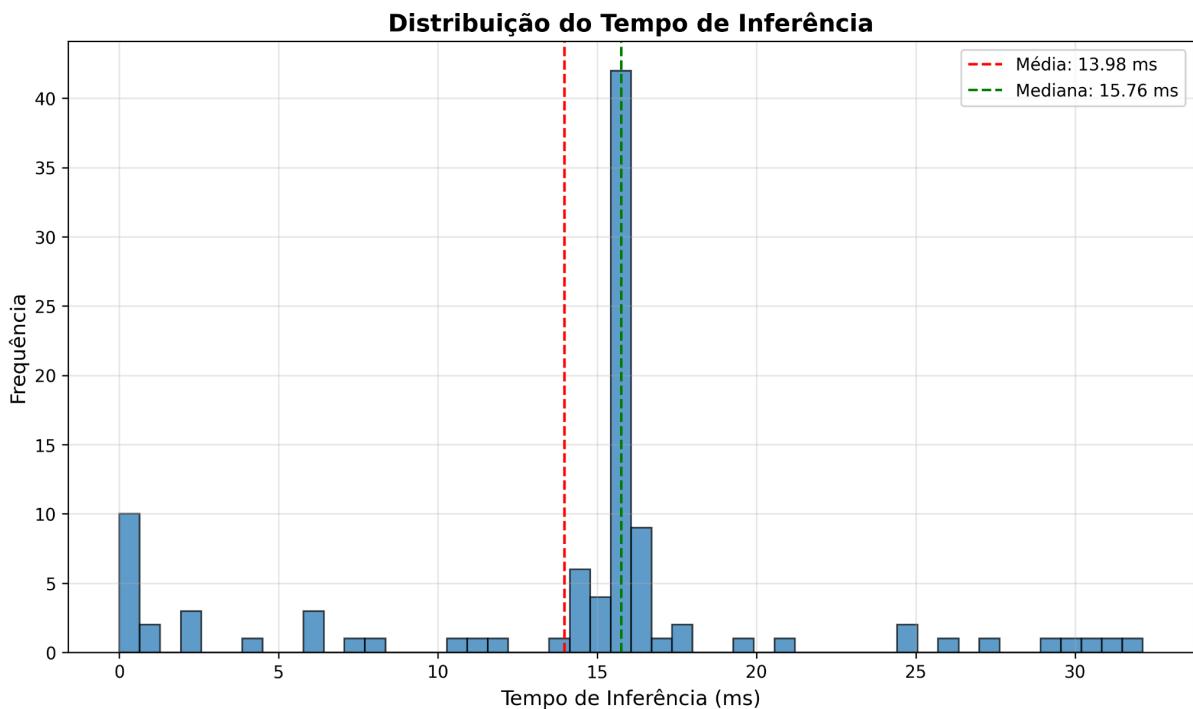


Figura 3 – Distribuição do Tempo de Inferência Fonte: Elaborado pelo autor (2025).

6.2.2 Análise Qualitativa

Visualmente, o modelo demonstrou generalização eficaz em diferentes contextos (Figura 4) e capacidade de distinguir detalhes morfológicos finos em *close-ups* (Figura 5).

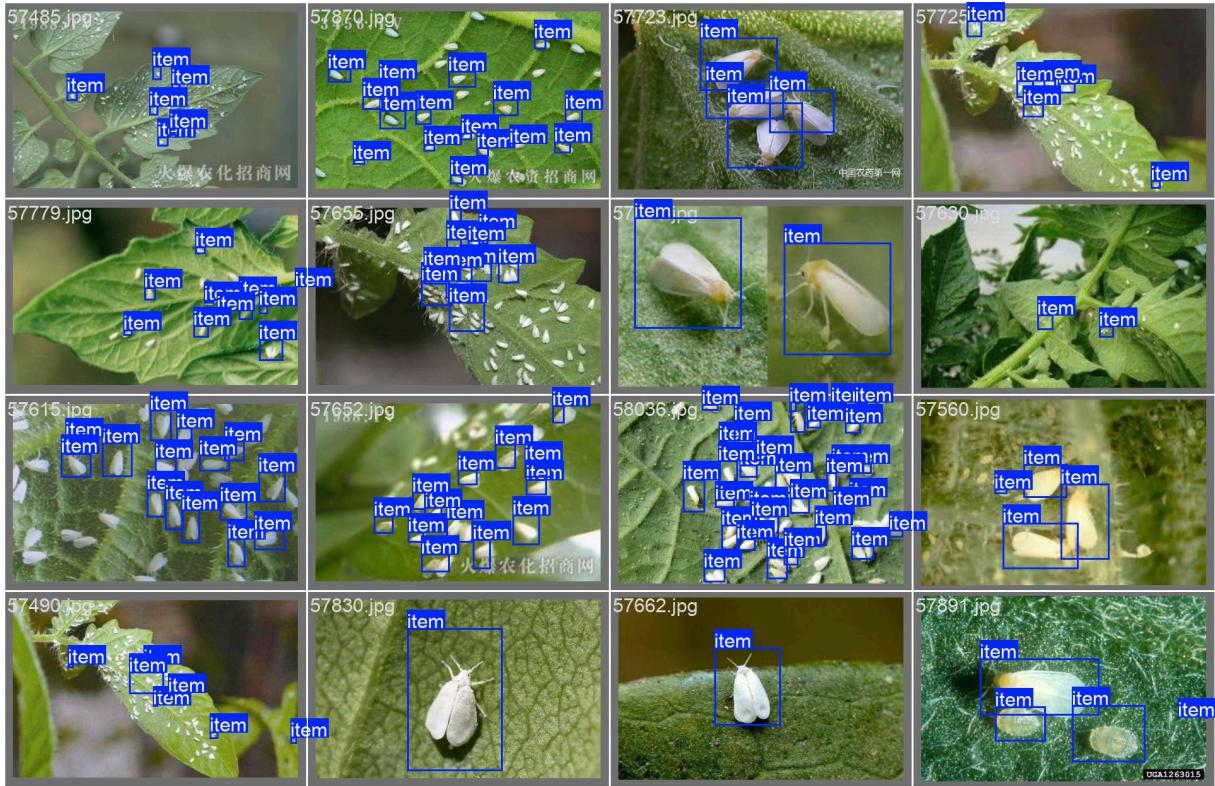


Figura 4 – Lote de Validação do Modelo Fonte: Elaborado pelo autor (2025).



Figura 5 – Detecção de Detalhes Morfológicos Fonte: Elaborado pelo autor (2025).

A robustez em cenários de alta densidade (Figura 6) confirma o sucesso da estratégia de treinamento adotada.



Figura 6 – Robustez em Alta Densidade Fonte: Elaborado pelo autor (2025).

6.3 Próximos Passos e Resultados Esperados

Com os componentes fundamentais (Módulo 1 e Software do Módulo 2) validados, as próximas etapas do projeto focam na integração física e na expansão do sistema para monitoramento visual.

6.3.1 Integração de Hardware do Módulo 2 (Armadilha Fotográfica) O principal ponto a ser desenvolvido é a **construção física da armadilha inteligente**. Isso envolve embarcar o modelo YOLOv8s (já validado) no Raspberry Pi Zero 2 W.

- **Desafio:** Otimizar o modelo para o formato TensorFlow Lite para garantir que a inferência ocorra localmente (*Edge Computing*) sem depender de conexão contínua para processamento de vídeo.

- **Resultado Esperado:** Um dispositivo autônomo que captura imagens da armadilha adesiva periodicamente, realiza a contagem e envia apenas o valor numérico para o dashboard.

6.3.2 Implementação do Módulo 3 (Monitoramento Visual da Plantação) Será desenvolvido o **Módulo 3**, focado na saúde macroscópica da lavoura.

- **Desenvolvimento:** Integração de uma câmera IP ou webcam conectada ao sistema para enviar *snapshots* ou *stream* de vídeo da plantaçāo.
- **Objetivo:** Permitir que o produtor correlacione visualmente os dados dos sensores (ex: baixa umidade do solo) com o aspecto físico das plantas (ex: folhas murchas) através do mesmo painel de controle.

6.3.3 Consolidação da Plataforma Web A etapa final consiste na **unificação dos dados**. O dashboard, que atualmente exibe dados do Módulo 1, será expandido para incluir:

- Gráficos de evolução da população de pragas (dados do Módulo 2).
- Galeria de imagens ou feed de vídeo (dados do Módulo 3).
- Sistema de alertas automatizados (ex: notificar usuário se a temperatura > 30°C e contagem de pragas > 50).

7 – Cronograma

Ano 2026	3	4	5	6	7	8	9	10	11	12
Levantamento Bibliográfico	X	X	X							
Elaboração do projeto de pesquisa			X	X	X					
Encaminhamento ao CEP				X						
Coleta de dados					X	X	X			
Análise e discussão dos dados							X	X		

Conclusão do estudo							X		
Apresentação								X	X

8 – Descrição Orçamentária

A seguir, apresenta-se a listagem com o orçamento discriminado dos gastos envolvidos na execução da pesquisa. O custeio das despesas envolvidas na execução será de responsabilidade do próprio autor e empréstimo de equipamentos da instituição.

Módulo	Hardware	Valores
1. Nó de Solo e Ambiente	ESP32 (NodeMCU)	R\$ 40 - R\$ 90
	Sensor Capacitivo de Umidade	R\$ 20 - R\$ 40
	Sensor BME280 (Clima)	R\$ 30 - R\$ 60
	Módulo de pH (com sonda)	R\$ 100 - R\$ 250
	Sensor de Luminosidade (BH1750)	R\$ 15 - R\$ 30
2. Armadilha de Pragas	Raspberry Pi (Zero 2 W / 4)	R\$ 200 - R\$ 500
	Módulo de Câmera Oficial Pi	R\$ 100 - R\$ 200
3. Monitoramento de plantação	Câmera de Segurança Externa Wi-Fi PTZ (Pan-Tilt-Zoom)	R\$ 300 - R\$ 800
	Raspberry Pi 4	R\$ 400 - R\$ 700
	Poste ou Mastro de Suporte + Ponto de Energia + Cobertura Wi-Fi	Custo variável
	Soma: R\$ 1.355 (mínimo) e R\$ 2.970 (máximo)	

9- Publicação do Trabalho

Após a sua conclusão e aprovação, pretende-se publicar os resultados deste Trabalho de Conclusão de Curso. O principal meio de divulgação será a publicação do trabalho completo no Repositório Digital da Fundação Hermínio Ometto além de outras plataformas, tornando-o acessível para consulta pela comunidade acadêmica

Adicionalmente, avalia-se a possibilidade de condensar a metodologia e os resultados obtidos, com ênfase no desenvolvimento do sistema de visão computacional, em um artigo científico. Este artigo poderá ser submetido para apresentação em congressos ou simpósios nacionais nas áreas de Engenharia de Computação e Inteligência Artificial, visando compartilhar o conhecimento adquirido e a solução tecnológica desenvolvida com outros pesquisadores e profissionais da área..

10 - CONCLUSÃO

Este trabalho **tem como objetivo** desenvolver um protótipo funcional de um sistema de monitoramento agrícola inteligente e de baixo custo, que integra dados de solo, ambiente e pragas para auxiliar na tomada de decisão de pequenos produtores. A proposta combina a prototipagem de hardware com sensores IoT, o desenvolvimento de um modelo de visão computacional baseado em Redes Neurais Convolucionais (CNNs) para detecção de pragas, e a criação de uma plataforma web para centralização e visualização dos dados.

A abordagem metodológica **foi dividida** no desenvolvimento de três módulos principais: um nó de sensores baseado em ESP32 para coleta de dados de solo e ambiente; uma armadilha fotográfica inteligente (Módulo 2) utilizando Raspberry Pi e uma CNN da arquitetura YOLO otimizada para TensorFlow Lite; e um sistema de monitoramento por câmeras para análise da saúde da vegetação (Módulo 3), todos comunicando-se via MQTT com uma plataforma de gerenciamento web.

Os resultados **esperados** ao final da execução do projeto incluem a demonstração da funcionalidade integrada do sistema. **Espera-se que** o nó de sensores transmita leituras ambientais e de solo de forma confiável, que a CNN embarcada no Módulo 2 alcance uma acurácia satisfatória (quantificada pela métrica mAP) na detecção e classificação das

pragas-alvo em imagens capturadas pela armadilha, e que a plataforma web exiba essas informações de forma clara e em tempo real através de um dashboard interativo. A validação desses componentes **deverá demonstrar** a viabilidade técnica da solução proposta.

Entre as principais contribuições **esperadas** do método proposto, destacam-se a integração de hardware de baixo custo (Raspberry Pi, ESP32) com software de código aberto (YOLO/TensorFlow Lite, Apache/PHP/Flask), resultando em uma solução potencialmente acessível para pequenos produtores, em contraste com sistemas comerciais de alto custo. A aplicação de uma CNN otimizada para um sistema embarcado **representará** um diferencial técnico relevante. Por outro lado, limitações potenciais **podem incluir** a dependência da qualidade e representatividade do dataset de imagens para a acurácia da CNN, a necessidade de calibração periódica dos sensores de solo, e os desafios inerentes à infraestrutura (energia e conectividade Wi-Fi) para a implantação robusta dos módulos em campo.

Os resultados **esperados** sugerem que a abordagem **poderá ser aplicada** como uma ferramenta de suporte à decisão para pequenos produtores, viabilizando princípios de agricultura de precisão em contextos onde soluções comerciais são inviáveis. O sistema **tem o potencial** de fornecer alertas precoces sobre infestações de pragas e indicar necessidades hídricas ou nutricionais baseadas em dados, contribuindo para a otimização do uso de insumos e práticas de manejo mais sustentáveis.

Para trabalhos futuros, propõe-se a expansão do dataset de imagens para incluir um maior número de espécies de pragas e maior variabilidade de condições ambientais, a investigação de arquiteturas de CNN mais recentes ou customizadas para otimizar ainda mais a acurácia e a eficiência computacional no Raspberry Pi. Sugere-se também a integração dos dados de contagem de pragas com os dados ambientais coletados pelo Módulo 1 para desenvolver modelos preditivos de risco de infestação, utilizando técnicas de séries temporais ou Machine Learning. Por fim, a validação do sistema em condições reais de campo por um período de cultivo completo seria um passo fundamental para avaliar sua robustez e impacto prático.

Em síntese, o trabalho **visa apresentar e validar** uma solução integrada e tecnicamente viável para a automação do monitoramento agrícola em pequena escala, **contribuindo potencialmente** para o avanço da aplicação de tecnologias da Agricultura 4.0 em um segmento fundamental da produção de alimentos.

11 – REFERÊNCIAS BIBLIOGRÁFICAS

Asma Khan ,Sharaf J. Malebary ,L. Minh Dang ,Faisal Binzagr ,Hyoung-Kyu Song and Hyeonjoon Moon. **AI-Enabled Crop Management Framework for Pest Detection Using Visual Sensor Data**

Dimitrios Kapetas ,Panagiotis Christakakis ,Sofia Faliagka ,Nikolaos Katsoulas , and Eleftheria Maria Pechlivani. **AI-Driven Insect Detection, Real-Time Monitoring, and Population Forecasting in Greenhouses**

B Kariyanna, M Sowjanya. **Unravelling the use of artificial intelligence in management of insect pests**

Kushagra Sharma, Shiv Kumar Shivandu. **Integrating artificial intelligence and Internet of Things (IoT) for enhanced crop monitoring and management in precision agriculture**

Oliveira, Victor Augusto. Sistema Inteligente de Monitoramento Agrícola. Título do periódico abreviado. Data de publicação; volume (número): página inicial-final do artigo.